



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

Отчет по лабораторной работе № 1
«Разведочный анализ данных.
Исследование и визуализация данных»

по дисциплине «Технологии машинного обучения»

Студент

ИУ5-64Б

(Группа)

(Подпись, дата)

Н.А. Чернев

(И.О. Фамилия)

Преподаватель

Ю.Е. Гапанюк

(Подпись, дата)

(И.О. Фамилия)

2026 г.

Цель работы

Изучение различных методов визуализации данных и проведение разведочного анализа.

Описание задания

1. Выбрать датасет без пропусков из scikit-learn.
2. Исследовать основные характеристики: размер, типы признаков.
3. Провести визуальный анализ через гистограммы, scatter plots, box plots.
4. Вычислить корреляционную матрицу и интерпретировать зависимости.

Выбранный датасет

Wine dataset из scikit-learn. Датасет содержит результаты химического анализа вин трех производителей (178 образцов, 13 числовых признаков).

Загрузка данных и импорт библиотек

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5 from sklearn.datasets import load_wine
6
7 # Загрузка датасета
8 wine = load_wine()
9 df = pd.DataFrame(wine.data, columns=wine.feature_names)
10 df['target'] = wine.target
11 df['target_name'] = df['target'].map({0: 'class_0', 1: 'class_1', 2: 'class_2'})
12
13 # Информация о датасете
14 print(f"Shape: {df.shape}") # (178, 14)
15 print(f"Missing values: {df.isnull().sum().sum()}") # 0
```

Основные характеристики датасета

- **Размер:** 178 образцов, 13 признаков
- **Классы:** 3 класса вин (сбалансированы)
- **Пропуски:** отсутствуют
- **Признаки:** alcohol, malic_acid, ash, flavanoids, color_intensity, proline и др.

Описательные статистики

```
1 # Базовая статистика
2 print(df.describe())
3
4 # Проверка типов и пропусков
5 print(df.info())
6 print("Соотношение классов:", df['target'].value_counts().to_dict())
```

Визуальное исследование

Распределение признаков по классам

```
1 # Гистограммы для каждого признака
2 fig, axes = plt.subplots(4, 4, figsize=(18, 14))
3 axes = axes.flatten()
4
5 colors = ['#FF6B6B', '#4ECDC4', '#45B7D1']
6 for i, col in enumerate(wine.feature_names):
7     ax = axes[i]
8     for cls in sorted(df['target'].unique()):
9         data = df[df['target'] == cls][col]
10        ax.hist(data, alpha=0.6, label=f'Class {cls}', color=colors[cls])
11    ax.set_title(col, fontweight='bold')
12    ax.set_xlabel('Значение')
13    ax.set_ylabel('Частота')
14    ax.legend()
15
16 plt.tight_layout()
17 plt.savefig('histograms.png', dpi=150, bbox_inches='tight')
18 plt.show()
```




Рисунок 1 — Гистограммы распределения признаков по классам

Box plots для анализа распределений

```
1 # Box plots
2 fig, axes = plt.subplots(4, 4, figsize=(18, 14))
3 axes = axes.flatten()
4
5 for i, col in enumerate(wine.feature_names):
6     ax = axes[i]
7     sns.boxplot(data=df, x='target_name', y=col, ax=ax, palette=colors)
```

```

8     ax.set_title(col, fontweight='bold')
9     ax.set_ylabel('Значение')
10
11 plt.tight_layout()
12 plt.savefig('boxplots.png', dpi=150, bbox_inches='tight')
13 plt.show()

```




Рисунок 2 — Box plots для анализа распределений признаков по классам

Анализ корреляции признаков

Корреляционная матрица

```

1 # Вычисление корреляции
2 corr_matrix = df[wine.feature_names].corr()
3
4 # Heatmap корреляциями
5 fig, ax = plt.subplots(figsize=(14, 10))
6 mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
7
8 sns.heatmap(corr_matrix, mask=mask, annot=True, fmt='.2f',
9             cmap='coolwarm', center=0, ax=ax, square=True)
10 ax.set_title('Корреляционная матрица признаков Wine', fontweight='bold', fontsize=14)
11
12 plt.tight_layout()
13 plt.savefig('correlation_matrix.png', dpi=150, bbox_inches='tight')
14 plt.show()
15
16 # Топ корреляций целевой переменной
17 target_corr = df[wine.feature_names].corrwith(df['target']).sort_values(ascending=False)

```

```

18 print("\nТопn признаков по корреляции с целевой переменной : ")
19 print(target_corr.head(5))

```




Рисунок 3 — Корреляционная матрица признаков датасета Wine

Ключевые корреляции

- **alcohol** ↔ **color_intensity**: $r \approx 0.55$ (положительная)
- **alcohol** ↔ **proline**: $r \approx 0.64$ (положительная)
- **flavanoids** ↔ **color_intensity**: $r \approx 0.65$ (положительная)
- **malic_acid** ↔ **alcohol**: $r \approx -0.32$ (отрицательная)

Pairplot для избранных признаков

```

1 # Pairplot
2 selected = ['alcohol', 'flavanoids', 'color_intensity', 'proline', 'target_name']
3 g = sns.pairplot(df[selected], hue='target_name', palette=colors,
4                 diag_kind='kde', plot_kws={'alpha': 0.6, 's': 80})
5 g.fig.suptitle('Pairplot ключевых признаков Wine', y=1.001, fontsize=14)
6
7 plt.savefig('pairplot.png', dpi=150, bbox_inches='tight')
8 plt.show()

```

Violin-plots выбранных признаков по классам




Рисунок 4 — Pairplot для ключевых признаков с разделением по классам

Дополнительные анализы

```

1 # Скриплет- распределения признаков
2 fig, axes = plt.subplots(2, 3, figsize=(15, 10))
3 # Visualize additional features...
4 plt.savefig('violin_plots.png', dpi=150, bbox_inches='tight')
5 plt.show()
6
7 # Скаттерплоты- пар признаков
8 fig, axes = plt.subplots(2, 2, figsize=(12, 10))
9 # Scatter plots for feature pairs...
10 plt.savefig('scatter_pairs.png', dpi=150, bbox_inches='tight')
11 plt.show()

```

Выводы

1. Датасет Wine хорошо структурирован без пропусков и легко разделяется на классы.
2. Признаки **alcohol**, **flavanoids** и **color_intensity** показывают наилучшую разделяющую способность.
3. Обнаружены сильные положительные корреляции между рядом признаков (alcohol-proline, flavanoids-color_intensity).
4. Классы визуально хорошо отделяются в многомерном пространстве признаков.

Диаграммы рассеяния пар признаков




Рисунок 5 — Violin plots для отобранных признаков по классам

Pair plot (5 ключевых признаков)




Рисунок 6 — Скаттер-плоты пар признаков с разделением по классам




Рисунок 7 — Корреляция признаков с целевой переменной