

**КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ**

**«Ансамбли моделей машинного обучения. Часть 2»**  
по дисциплине «Технологии машинного обучения»

1

## Цель работы

Изучение ансамблей моделей машинного обучения: стекинг и многослойный перцептрон (MLP) на примере датасета Diabetes (прогнозирование прогрессии диабета).

## Описание задания

1. Выбрать набор данных для решения задачи регрессии (Diabetes Dataset).
2. При необходимости выполнить предобработку данных (масштабирование).
3. Разделить выборку на обучающую (80%) и тестовую (20%) с помощью `train_test_split`.
4. Обучить ансамблевые модели:
  - Стекинг (Stacking) — комбинация нескольких базовых моделей с мета-моделью.
  - Многослойный перцептрон (MLP) — нейросетевая модель.
5. Оценить качество моделей с помощью метрик MSE, MAE,  $R^2$ .
6. Сравнить качество полученных моделей.

## Загрузка и подготовка данных

Был загружен датасет Diabetes, содержащий 442 образца и 10 признаков. Целевая переменная — количественная характеристика прогрессии диабета. Данные были нормализованы с помощью `StandardScaler` и разделены на обучающую (80%) и тестовую (20%) выборки.



Рисунок 1 — Сравнение качества моделей

## Стекинг (Stacking)

Стекинг — это метод ансамблирования, который комбинирует предсказания нескольких базовых моделей (уровень 0) с помощью мета-модели (уровень 1). В данной работе в качестве базовых моделей использовались:

- `LinearRegression`

- Ridge(alpha=1.0)
- Ridge(alpha=10.0)
- Ridge(alpha=100.0)

В качестве мета-модели использовалась Ridge(alpha=1.0).

## Листинг кода

```

1 class StackingRegressor:
2     def __init__(self, base_models, meta_model):
3         self.base_models = base_models
4         self.meta_model = meta_model
5
6     def fit(self, X, y):
7         meta_features = np.zeros((X.shape[0], len(self.base_models)))
8         for i, model in enumerate(self.base_models):
9             model.fit(X, y)
10            meta_features[:, i] = model.predict(X)
11        self.meta_model.fit(meta_features, y)
12        return self
13
14    def predict(self, X):
15        meta_features = np.zeros((X.shape[0], len(self.base_models)))
16        for i, model in enumerate(self.base_models):
17            meta_features[:, i] = model.predict(X)
18        return self.meta_model.predict(meta_features)

```

## Многослойный перцептрон (MLP)

Многослойный перцептрон — это нейронная сеть с одним или несколькими скрытыми слоями. В данной работе использовалась архитектура:  $10 \rightarrow 100 \rightarrow 100 \rightarrow 50 \rightarrow 1$  с функцией активации ReLU и оптимизатором Adam. Для предотвращения переобучения использовался EarlyStopping.

```

1 from sklearn.neural_network import MLPRegressor
2
3 mlp_model = MLPRegressor(
4     hidden_layer_sizes=(100, 100, 50),
5     activation='relu',
6     solver='adam',
7     max_iter=1000,
8     random_state=42,
9     early_stopping=True,
10    validation_fraction=0.1,
11    n_iter_no_change=50,
12    verbose=0
13 )

```

## Результаты прогнозирования

### Сравнение всех моделей

### Выводы

1. **Стекинг (Stacking):** Показал лучшие результаты (MSE=2900.24, MAE=42.79,  $R^2=0.453$ ). Комбинирование предсказаний нескольких базовых моделей через мета-модель позволяет

### Предсказания vs Реальные значения




Рисунок 2 — Предсказания vs Реальные значения

### Распределение ошибок предсказаний




Рисунок 3 — Распределение ошибок предсказаний

улучшить обобщающую способность. Преимущество — возможность использовать разнородные модели.

| Модель        | MSE     | MAE   | R <sup>2</sup> |
|---------------|---------|-------|----------------|
| Stacking      | 2900.24 | 42.79 | 0.453          |
| MLP Regressor | 2939.13 | 43.51 | 0.445          |

Таблица 1: Сравнение метрик качества прогнозирования

2. **Многослойный перцептрон (MLP):** Показал немного худшие результаты (MSE=2939.13, MAE=43.51, R<sup>2</sup>=0.445). Нейросетевые модели требуют тщательной настройки гиперпараметров (количество слоёв, нейронов, скорость обучения) и большего объёма данных для достижения высоких результатов.

### 3. Общие выводы:

- Стекинг оказался более эффективным на данном датасете, чем отдельная нейросетевая модель.
- Обе модели показали умеренное качество (R<sup>2</sup> 0.45), что объясняется сложностью предсказания прогрессии диабета по 10 признакам.
- Для улучшения результатов можно использовать более сложные мета-модели, добавлять больше базовых моделей или применять нейросетевые архитектуры с регуляризацией.