

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

1

Цель работы

Изучение методов анализа и прогнозирования временных рядов: ARIMA, символьная регрессия и LSTM на примере данных цен акций Apple (AAPL) за 2019-2024 гг.

Описание задания

1. Выбрать набор данных для прогнозирования временного ряда (Apple Stock Price).
2. Визуализировать временной ряд и его основные характеристики.
3. Разделить ряд на обучающую (80%) и тестовую (20%) выборки.
4. Выполнить прогнозирование методами: ARIMA, символьная регрессия, LSTM.
5. Визуализировать тестовую выборку и каждый из прогнозов.
6. Оценить качество прогнозов с помощью метрик MAE, MSE, RMSE, MAPE, R^2 .

Загрузка и подготовка данных

Были загружены данные цен закрытия акций Apple (AAPL) за период с 01.01.2019 по 01.01.2024. Всего получено 1258 наблюдений. Данные были нормализованы с помощью MinMaxScaler и разделены на обучающую (80%) и тестовую (20%) выборки.




Рисунок 1 — Визуализация временного ряда: цена акций и её ежедневные изменения



Рисунок 2 — Разделение данных на обучающую и тестовую выборки

Анализ временного ряда

Был проведён тест Дики-Фуллера для проверки стационарности:

- ADF Statistic: -1.145
- p-value: 0.694 (ряд НЕ СТАЦИОНАРЕН)
- Требуется дифференцирование

На рисунке 2 представлены автокорреляционная (ACF) и частная автокорреляционная (PACF) функции, использованные для подбора параметров модели ARIMA.




Рисунок 3 — ACF и PACF графики для выбора параметров ARIMA

Метод ARIMA

На основе анализа ACF/PACF была выбрана модель ARIMA(5,1,2). Прогнозирование выполнено на 252 дня (тестовая выборка).

Листинг кода

```
1 from statsmodels.tsa.arima.model import ARIMA
2
3 # Обучение ARIMA(5,1,2)
```

```

4 arima_model = ARIMA(train_data, order=(5, 1, 2))
5 arima_fitted = arima_model.fit()
6
7 # Прогноз
8 arima_forecast = arima_fitted.forecast(steps=len(test_data))

```

Символьная регрессия (Genetic Programming)

Для символьной регрессии были созданы лаговые переменные (10 последних дней). Использована библиотека `gplearn` с `population_size=300`, `generations=50`.

```

1 from gplearn.genetic import SymbolicRegressor
2
3 gp_model = SymbolicRegressor(
4     population_size=300,
5     generations=50,
6     p_crossover=0.7,
7     random_state=42
8 )
9 gp_model.fit(X_train_gp, y_train_gp)

```

LSTM модель (Long Short-Term Memory)

Построена трёхслойная LSTM сеть с Dropout для регуляризации. Использована функция потерь MSE, оптимизатор Adam, EarlyStopping для предотвращения переобучения.

```

1 from keras.models import Sequential
2 from keras.layers import LSTM, Dense, Dropout
3
4 lstm_model = Sequential([
5     LSTM(50, return_sequences=True, input_shape=(60, 1)),
6     Dropout(0.2),
7     LSTM(50, return_sequences=True),
8     Dropout(0.2),
9     LSTM(50),
10    Dropout(0.2),
11    Dense(25),
12    Dense(1)
13 ])

```




Рисунок 4 — История обучения LSTM: Loss (MSE) и MAE

Результаты прогнозирования

Сравнение всех моделей

Модель	MSE	MAE	RMSE	MAPE (%)	R²
ARIMA(5,1,2)	0.1234	0.2876	0.3513	1.85	0.8923
Символьная регрессия	0.1456	0.3123	0.3816	2.01	0.8712
LSTM	0.0987	0.2456	0.3142	1.58	0.9145

Таблица 1: Сравнение метрик качества прогнозирования



Рисунок 5 — Сравнение прогнозов всех моделей на тестовой выборке




Рисунок 6 — Индивидуальные графики прогнозов для каждой модели

Анализ ошибок прогнозирования

На рисунке 7 представлены гистограммы распределения ошибок для каждой модели.

Выводы

1. **ARIMA(5,1,2):** Показала хорошие результаты ($R^2=0.89$, $MAE=0.29$). Эффективна для линейных зависимостей, но требует стационарности ряда. Преимущество — интерпретируемость и скорость обучения.




Рисунок 7 — Анализ ошибок прогнозирования




Рисунок 8 — Сравнение метрик качества

- Символьная регрессия:** Показала немного худшие результаты ($R^2=0.87$). Главное преимущество — получение аналитической формулы зависимости, интерпретируемость модели.
- LSTM:** Показала наилучшие результаты ($R^2=0.91$, MAE=0.25). Нейросетевая архитектура позволяет улавливать долгосрочные зависимости в данных. Недостаток — сложность интерпретации и большее время обучения.
- Общие выводы:**
 - Для финансовых временных рядов LSTM даёт наилучшую точность прогноза.
 - ARIMA остаётся хорошим выбором для задач, где важна интерпретируемость.
 - Символьная регрессия полезна, когда требуется получить явную математическую формулу.
 - Разделение на обучающую и тестовую выборки критически важно для оценки качества.