

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

1

Цель работы

Изучение методов кластеризации и снижения размерности на примере набора данных Wine (характеристики вин, 13 признаков).

Описание задания

1. Выбрать набор данных (Wine Dataset) и создать датасет D1 из 13 признаков (исключая целевой).
2. С использованием метода главных компонент (PCA) снизить размерность D1 до двух компонент → датасет D2.
3. С использованием алгоритма t-SNE снизить размерность D1 до двух компонент → датасет D3.
4. Визуализировать точки D2 и D3, сравнить качество выделения кластеров.
5. Провести кластеризацию D1, D2, D3 методами K-Means, DBSCAN, Spectral Clustering, Agglomerative Clustering.
6. Оценить качество кластеризации с помощью метрик ARI, Silhouette Score, Davies-Bouldin Index.
7. Сделать выводы о наилучших методах для каждого датасета.

Снижение размерности данных

Метод главных компонент (PCA) → D2

Было выполнено снижение размерности с 13 признаков до 2 главных компонент. Суммарная объясненная дисперсия составила **55.5%**. На рисунке 1 представлен вклад признаков в главные компоненты.




Рисунок 8 — Сравнение метрик качества

Алгоритм t-SNE → D3

t-SNE (perplexity=30) позволил получить двумерное представление данных, лучше сохраняющее локальную структуру.

Визуализация D2 и D3

На рисунке 2 показаны проекции точек на плоскости PCA и t-SNE с цветовой маркировкой по истинным классам вин.




Рис. 1: Сравнение визуализации PCA (D2) и t-SNE (D3)

Анализ: Кластеры наиболее явно выделены на **t-SNE (D3)**, так как этот метод лучше сохраняет локальные структуры данных и разделяет нелинейные зависимости.

Кластеризация датасетов

Используемые методы

- K-Means (k=3)
- DBSCAN (eps=0.5, min_samples=5)
- Spectral Clustering (k=3, affinity='nearest_neighbors')
- Agglomerative Clustering (k=3, linkage='ward')

Метрики оценки качества

- **ARI (Adjusted Rand Index)** — сходство с истинной разметкой (чем ближе к 1, тем лучше).
- **Silhouette Score** — компактность и разделимость кластеров (от -1 до 1).
- **Davies-Bouldin Index** — отношение суммы внутрикластерных расстояний к межкластерным (чем меньше, тем лучше).




Рис. 2: Сравнение ARI для D1, D2, D3

Результаты кластеризации D1 (13 признаков)

Визуализация кластеризации D2 и D3

На рисунках 4 и 5 показаны результаты кластеризации на пространствах PCA и t-SNE.




Рис. 3: Кластеризация датасета D2 (PCA)

Сравнение всех метрик

На рисунках 6 и 7 представлены тепловая карта ARI и финальное сравнение методов.




Рис. 4: Кластеризация датасета D3 (t-SNE)

Анализ результатов

Лучшие методы для каждого датасета

- **D1 (13 признаков):** Spectral Clustering (ARI = 0.86) — лучше всех справился с многомерным пространством.
- **D2 (PCA):** K-Means и Agglomerative (ARI $\approx$ 0.88) — PCA упростил форму кластеров, что подходит для центроидных методов.
- **D3 (t-SNE):** K-Means (ARI = 0.90) — t-SNE сформировал плотные, хорошо разделенные сферические кластеры.

Проблемы DBSCAN

DBSCAN показал худшие результаты на всех датасетах при параметрах $\text{eps}=0.5$, $\text{min_samples}=5$:

- D1: 96% точек отнесены к шуму
- D2: 43% шума
- D3: 27% шума




Рис. 5: Тепловая карта ARI для всех комбинаций




Рис. 6: Финальное сравнение: средний ARI и лучшие методы

Это связано с тем, что плотность кластеров в Wine различна, и фиксированный `eps` не подходит. Подбор параметров (`eps=0.7`, `min_samples=5`) повышает ARI до 0.6 на D3.

Выводы

1. **Снижение размерности:** t-SNE (D3) показал более четкое разделение кластеров по сравнению с PCA (D2), так как он учитывает нелинейные зависимости в данных.
2. **Влияние размерности:** Кластеризация на исходных данных (D1) сложнее из-за ”проклятия размерности”. После PCA и t-SNE качество кластеризации возрастает.
3. **Выбор метода:**
 - K-Means — лучший выбор для данных после t-SNE (компактные сферические кластеры).
 - Spectral Clustering — предпочтителен для многомерных данных (D1).
 - DBSCAN требует тщательного подбора параметров и не подходит для Wine ”из коробки”.
4. **Метрики:** ARI лучше всего отражает сходство с истинной разметкой; Silhouette и Davies-Bouldin полезны для оценки внутренней структуры кластеров без эталонных меток.