



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

Построение и оптимизация моделей

машинного обучения для предсказания

годовой стоимости медицинской страховки

Студент ИУ5-64Б
(Группа)

(Подпись, дата)

Н.А. Чернев
(И.О.Фамилия)

Руководитель

(Подпись, дата)

Ю.Е. Гапанюк
(И.О.Фамилия)

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ

Заведующий кафедрой ИУ5
(Индекс)

В.И. Терехов
(И.О.Фамилия)

« 09 » февраля 2026 г.

ЗАДАНИЕ
на выполнение научно-исследовательской работы

по теме Построение и оптимизация моделей машинного обучения
для предсказания годовой стоимости медицинской страховки

Студент группы ИУ5-64Б

Чернев Николай Андреевич

(Фамилия, имя, отчество)

Направленность НИР (учебная, исследовательская, практическая, производственная, др.)

УЧЕБНАЯ

Источник тематики (кафедра, предприятие, НИР) КАФЕДРА

График выполнения НИР: 25% к 4 нед., 50% к 9 нед., 75% к 12 нед., 100% к 15 нед.

Техническое задание

Оформление научно-исследовательской работы:

Расчетно-пояснительная записка на _____ листах формата А4.

Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.)

Дата выдачи задания « 09 » февраля 2026 г.

Руководитель НИР

(Подпись, дата)

Ю.Е. Гапанюк

(И.О.Фамилия)

Студент

(Подпись, дата)

Н.А Чернев

(И.О.Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

СОДЕРЖАНИЕ

<i>СОДЕРЖАНИЕ.....</i>	<i>3</i>
<i>ВВЕДЕНИЕ.....</i>	<i>4</i>
<i>ЗАГРУЗКА ДАННЫХ.....</i>	<i>6</i>
<i>РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ.....</i>	<i>7</i>
<i>КОРРЕЛЯЦИОННЫЙ АНАЛИЗ ДАННЫХ.....</i>	<i>9</i>
<i>ОБРАБОТКА ДАННЫХ И КОНСТРУИРОВАНИЕ ПРИЗНАКОВ.....</i>	<i>11</i>
<i>ВЫБОР МЕТРИК КАЧЕСТВА</i>	<i>12</i>
<i>ПОСТРОЕНИЕ БАЗОВОГО РЕШЕНИЯ.....</i>	<i>13</i>
<i>ПОДБОР ГИПЕРПАРАМЕТРОВ</i>	<i>14</i>
<i>ВАЖНОСТЬ ПРИЗНАКОВ.....</i>	<i>15</i>
<i>ЗАКЛЮЧЕНИЕ</i>	<i>19</i>
<i>СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ</i>	<i>20</i>

ВВЕДЕНИЕ

Оценка финансовых рисков и прогнозирование затрат на медицинское обеспечение являются важнейшими бизнес-процессами для страховых и медицинских организаций. Традиционные актуарные методы расчета тарифов зачастую опираются на обобщенную статистику и не позволяют гибко учитывать сложные нелинейные зависимости между множеством разнородных индивидуальных факторов пациента (демография, образ жизни, медицинская история). Внедрение современных технологий машинного обучения (Machine Learning) предоставляет возможность создавать предиктивные системы высокой точности. Это позволяет автоматизировать расчет индивидуальных страховых премий (взносов), снижать финансовые риски компаний и оптимизировать распределение медицинских ресурсов.

Цель работы: построение оптимальной регрессионной модели для прогнозирования индивидуальной годовой стоимости медицинских услуг пациента на основе его персональных данных, а также разработка интерактивного веб-приложения для наглядной демонстрации результатов работы модели.

Задачи исследования:

- Выполнить загрузку и провести детальный разведочный анализ данных (EDA) Medical Insurance Cost Dataset.
- Реализовать предварительную обработку данных, кодирование категориальных признаков и масштабирование численных показателей.
- Провести конструирование новых признаков (Feature Engineering) для извлечения скрытых паттернов и улучшить предсказательную способность алгоритмов.
- Разработать и обучить базовые регрессионные решения (baseline) на основе девяти различных алгоритмов машинного обучения, включая ансамблевые методы.

- Выбрать и обосновать систему метрик оценки качества регрессии.
- Выполнить оптимизацию гиперпараметров для наиболее перспективных моделей с помощью методов кросс-валидации (GridSearchCV).
- Провести сравнительный анализ качества моделей до и после оптимизации, изучить графики обучения и важности признаков.
- Разработать и развернуть демонстрационное веб-приложение на базе фреймворка Streamlit.

ЗАГРУЗКА ДАННЫХ

В качестве эмпирической базы исследования использован набор данных Medical Insurance Cost Dataset, содержащий 7500 структурированных записей пациентов и 16 признаков, отражающих медико-экономические показатели. В таблице 1 приведено описание структуры признаков исходного датасета:

Таблица 1 - Спецификация признаков Medical Insurance Cost Dataset

Название признака	Тип данных	Описание признака
customer_id	Object (Строка)	Уникальный идентификатор клиента
age	Int64	Возраст клиента (от 18 до 65 лет)
gender	Object (Категориальный)	Пол застрахованного лица
bmi	Float64	Индекс массы тела (ИМТ)
children	Int64	Количество застрахованных детей-иждивенцев
smoker	Object (Категориальный)	Статус курения (Yes/No)
region	Object (Категориальный)	Регион проживания полисодержателя
occupation	Object (Категориальный)	Профессия / сфера занятости клиента
annual_income_usd	Int64	Расчетный годовой доход застрахованного (в USD)
exercise_level	Object (Категориальный)	Уровень физической активности (Low, Moderate, High)
chronic_diseases	Int64	Количество зафиксированных хронических заболеваний
doctor_visits_per_year	Int64	Общее число визитов к врачу за год
hospitalizations_last_year	Int64	Количество госпитализаций за прошлый год
alcohol_consumption_per_week	Int64	Среднее количество алкоголя в неделю (условные единицы)
insurance_plan	Object (Категориальный)	Выбранный пакет страхования (Basic, Standard, Premium)
annual_medical_cost_usd	Float64	Целевая переменная: Общая годовая стоимость медуслуг

РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ

На этапе разведочного анализа данных рассчитаны базовые статистические показатели непрерывных и дискретных распределений (среднее значение, стандартное отклонение, экстремумы, квантили).

Средний возраст застрахованных лиц составил 41.3 года, среднее значение ИМТ (bmi) равняется 28.05, что соответствует предожирению по классификации ВОЗ.

Целевая переменная `annual_medical_cost_usd` варьируется от \$1,500 до \$49,332 со средним значением \$17,912 и медианой \$16,361.

В процессе графического анализа построены следующие визуализации (с использованием Matplotlib и Seaborn):




Рисунок 1 – гистограмма распределения целевой переменной

Гистограмма распределения целевой переменной: Показала выраженную положительную (правостороннюю) асимметрию, что типично для данных по медицинским расходам, где основная масса пациентов имеет умеренные траты, а длинный "хвост" формируется за счет дорогостоящих страховых случаев.




Рисунок 2 – диаграммы рассеяния целевой переменной и
возраста/индекса массы тела

Диаграммы рассеяния (Scatter plots): Выявили явные положительные линейные и нелинейные тренды роста медицинских затрат при увеличении возраста пациента (age) и индекса массы тела (bmi).




Рисунок 3 – BoxPlot целевой переменной относительно smoker

Ящики с усами (Box plots): Визуализация целевой переменной в разрезе бинарного признака smoker продемонстрировала колоссальный сдвиг медианы расходов вверх для курящих пациентов, подтверждая гипотезу о курении как о ключевом факторе риска.

КОРРЕЛЯЦИОННЫЙ АНАЛИЗ ДАННЫХ

Для оценки линейной зависимости между непрерывными количественными признаками была рассчитана матрица коэффициентов корреляции Пирсона. На основе матрицы построена тепловая карта (sns.heatmap).




Рисунок 4 – матрица корреляций Пирсона

Анализ коэффициентов корреляции с целевой переменной `annual_medical_cost_usd` позволил сделать следующие выводы:

- Наблюдается устойчивая положительная корреляция со следующими показателями: возраст (`age`), индекс массы тела (`bmi`), количество

хронических заболеваний (chronic_diseases) и число прошлых госпитализаций (hospitalizations_last_year).

- Мультиколлинеарности (сильной взаимосвязи между независимыми признаками, превышающей уровень 0.7-0.8) обнаружено не было, что свидетельствует о стабильности будущих оценок линейных моделей.
- Сделан промежуточный вывод о высокой степени пригодности собранных данных для построения регрессионных математических моделей машинного обучения.

ОБРАБОТКА ДАННЫХ И КОНСТРУИРОВАНИЕ ПРИЗНАКОВ

Пайплайн предобработки данных был реализован в рамках следующей последовательности:

1. **Исключение неинформативных признаков:** Столбец `customer_id` удален из датафрейма (`df.drop`), так как он представляет собой случайный хэш-идентификатор, не несущий физического смысла.
2. **Кодирование категориальных переменных:** для всех строковых и текстовых признаков (`gender`, `smoker`, `region`, `occupation`, `exercise_level`, `insurance_plan`) применен метод порядкового кодирования на основе класса `LabelEncoder` из библиотеки `scikit-learn`.
3. **Конструирование признаков (Feature Engineering):** для повышения точности моделей усложнена признаковая база путем математического комбинирования имеющихся параметров:
 - Создан синергетический признак взаимодействия:
 $age_bmi_interaction = age \cdot bmi$ (отражает гипотезу усугубления рисков высокого ИМТ с возрастом).
 - Сформирован комплексный индекс медицинских рисков на основе сложения нормированных индикаторов хронических болезней, госпитализаций и частоты обращений к врачу.
 - Создан финансово-демографический коэффициент соотношения доходов к возрасту ($\frac{annual_income_usd}{age}$).

ВЫБОР МЕТРИК КАЧЕСТВА

Для всестороннего тестирования и сопоставления эффективности регрессоров были выбраны 3 классические метрики, зафиксированные в техническом задании дисциплины:

1. MAE (Mean Absolute Error) — средняя абсолютная ошибка:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Критерий выбора: измеряется непосредственно в долларах (единицах целевой метрики), легко интерпретируется бизнесом и устойчива к единичным аномальным выбросам в данных.

2. RMSE (Root Mean Squared Error) — корень из средней квадратичной ошибки:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Критерий выбора: за счет возведения разностей в квадрат накладывает жесткий математический штраф на крупные ошибки прогнозирования, сигнализируя о наличии критических сбоев модели.

3. R2-Score (Коэффициент детерминации):

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Критерий выбора: Относительная безразмерная метрика (обычно принимает значения от 0 до 1). Демонстрирует долю дисперсии целевого признака, объясненную построенным алгоритмом.

Разделение выборки. Массив данных объемом 7500 строк разделен с помощью `train_test_split` в пропорции 80% для обучения (6000 записей) и 20% для проведения отложенного тестирования (1500 записей). На обучающей подвыборке был обучен класс `StandardScaler`, осуществляющий Z-масштабирование (приведение к нулевому среднему и единичной дисперсии), после чего масштабирование применено к обоим подмножествам.

ПОСТРОЕНИЕ БАЗОВОГО РЕШЕНИЯ

В рамках исследования осуществлена инициализация и обучение «из коробки» (без изменения стандартных параметров) 9 регрессионных моделей:

- 1. Линейная регрессия (LinearRegression)
- 2. Гребневая регрессия (Ridge)
- 3. Регрессия Лассо (Lasso)
- 4. Дерево решений (DecisionTreeRegressor)
- 5. Метод К-ближайших соседей (KNeighborsRegressor)
- 6. Метод опорных векторов (SVR)
- 7. Случайный лес (Random Forest Regressor)
- 8. Градиентный бустинг (Gradient Boosting Regressor)
- 9. Адаптивный бустинг (AdaBoostRegressor)

Сводные результаты тестирования базовых моделей представлены в таблице 2:

Таблица 2. Метрики качества базовых моделей (Baseline)

Название модели	MAE (\$)	RMSE (\$)	R2 Score
Linear Regression	2450.12	3120.45	0.83
Ridge Regression	2450.35	3120.9	0.83
Lasso Regression	2449.95	3120.2	0.831
Decision Tree	2910.4	4150.1	0.701
K-Nearest Neighbors	2680.5	3640.25	0.769
Support Vector Regression	5850	7620	-0.012
Random Forest	1810.15	2480.6	0.893
Gradient Boosting	1845.2	2510.12	0.89
AdaBoost	2980.6	3820.4	0.745

Анализ baseline-решений: Случайный лес и Градиентный бустинг изначально продемонстрировали наилучшую обобщающую способность, показав значения коэффициента детерминации $R^2 \approx 0.89$, существенно опередив классические линейные подходы и значительно превзойдя SVR.

ПОДБОР ГИПЕРПАРАМЕТРОВ

Для улучшения предсказательной точности топ-3 выбранных моделей (Random Forest, Gradient Boosting, Ridge) был проведен полный перебор параметров по сетке с использованием стратегии кросс-валидации GridSearchCV (количество фолдов $K = 5$).

Конфигурация оптимизационных сеток:

- **Random Forest:** `n_estimators`: [50, 100, 200]; `max_depth`: [10, 20, 30]; `min_samples_split`: [2, 5, 10].
- **Gradient Boosting:** `n_estimators`: [50, 100, 200]; `learning_rate`: [0.01, 0.1, 0.2]; `max_depth`: [3, 5, 7].
- **Ridge:** `alpha`: [0.1, 1.0, 10.0, 100.0, 1000.0].

После нахождения лучших параметров модели были обучены повторно. Итоговое сопоставление точности до и после процедуры оптимизации отражено в таблице 3:

Таблица 3. Сравнение качества моделей до и после оптимизации параметров

Модель	Режим	MAE (\$)	RMSE (\$)	R2 Score
Random Forest	Baseline	1810.15	2480.6	0.893
	Оптимизированный	1620.4	2210.15	0.915
Gradient Boosting	Baseline	1845.2	2510.12	0.89
	Оптимизированный	1651.1	2242.3	0.912
Ridge Regression	Baseline	2450.35	3120.9	0.83
	Оптимизированный	2448.1	3118.5	0.831

Подбор гиперпараметров позволил ансамблевым алгоритмам совершить качественный прирост предсказательных свойств на 5–10%, выведя итоговое значение объясненной дисперсии R^2 на уровень выше 0.91.

ВАЖНОСТЬ ПРИЗНАКОВ

На основе лучшего регрессора (Random Forest (Opt)) был вызван программный атрибут `.feature_importances_`. Сформирован и выведен горизонтальный столбчатый график ранжирования факторов влияния.




Рисунок 5 – важность признаков модели Random Forest

Установлено, что наиболее весомыми предикторами, определяющими итоговую траекторию годовой стоимости медицинского страхования пациента, выступают:

1. Статус курения (`smoker`)
2. Возраст пациента (`age`)
3. Индекс массы тела (`bmi`)
4. Сконструированный признак взаимодействия `age_bmi_interaction`
5. Количество хронических заболеваний (`chronic_diseases`)

Графики обучения (Learning Curves). Построенные кривые зависимости ошибок обучения и валидации от объема выборки продемонстрировали постепенное сближение траекторий. Это подтверждает отсутствие выраженных дефектов недообучения (underfitting) или критического переобучения

(overfitting), указывая на высокую стабильность и стабильную устойчивость построенной системы.




Рисунок 6 – график обучения Random Forest

СОЗДАНИЕ ВЕБ-ПРИЛОЖЕНИЯ

В соответствии с техническим заданием на научно-исследовательскую работу, для демонстрации практической применимости построенных моделей машинного обучения было разработано интерактивное веб-приложение на базе веб-фреймворка Streamlit.

Разработанное приложение решает две ключевые задачи, разнесенные по соответствующим графическим вкладкам (Tabs):

1. **Вкладка «Обучение и оценка модели»:** Предоставляет пользователю (исследователю или аналитику) графический интерфейс для управления процессом обучения. Реализована возможность выбора семейства алгоритмов (Случайный лес или Линейная регрессия с возможностью L1/L2 регуляризации) и изменения их ключевых гиперпараметров (количество деревьев, максимальная глубина, сила регуляризации) с помощью интерактивных слайдеров. При нажатии кнопки модель переобучается, рассчитываются метрики качества (MAE, RMSE, R2) на отложенной тестовой выборке и перестраиваются графики.




Рисунок 7 – Вкладка «Обучение и оценка модели»

2. **Вкладка «Интерактивный прогноз»:** Представляет собой интерфейс конечного пользователя (андеррайтера страховой компании). Вкладка содержит структурированную форму (st.form) для ввода персональных, антропометрических и медицинских параметров нового пациента. При отправке данных приложение автоматически выполняет кодирование категориальных признаков, генерирует новые синтетические признаки (Feature Engineering) в соответствии с логикой исследования, масштабирует вектор признаков через StandardScaler и выводит предсказанную годовую стоимость страховки.

Оценка стоимости страховки для пациента

Настройте параметры ниже, чтобы описать демографические данные, состояние здоровья и медицинскую историю пациента.

Демография	Здоровье и привычки	План и мед. история
Возраст: 35	Индекс массы тела (ИМТ): 25.00	Визиты к врачу в год: 4
Пол: Female	Статус курения: No	Госпитализации в год: 0
Регион: Central	Уровень физической активности: High	Количество детей: 4
Профессия: Construction Worker	Потребление алкоголя (доз/неделя): 5	Класс страхового плана: Basic
Годовой доход (USD): 50000	Количество хронических заболеваний: 2	

Рассчитать стоимость

Прогнозируемая годовая стоимость медицинской страховки

\$8,910.85

Расчет выполнен на основе модели: Случайный лес (n_estimators=100, max_depth=10)

Рисунок 8 – вкладка «Интерактивный прогноз»

Для повышения визуальной эргономичности интерфейса были внедрены кастомные стили оформления с использованием CSS-инъекций (st.markdown с флагом unsafe_allow_html=True), формирующие контрастные карточки метрик и результатов прогнозирования.

ЗАКЛЮЧЕНИЕ

В ходе выполнения научно-исследовательской работы успешно реализован полный цикл разработки интеллектуальной системы предиктивного анализа медицинских расходов на базе набора данных *Medical Insurance Cost Dataset*.

Основные научно-практические результаты:

1. Проведен многофакторный разведочный анализ данных, обосновавший структуру зависимостей в предметной области.
2. Создан устойчивый конвейер предобработки данных и осуществлен Feature Engineering, поднявший общую информативность признакового пространства.
3. Построена линейка из 9 базовых моделей регрессии. Выявлено безусловное преимущество нелинейных ансамблевых алгоритмов (Random Forest, Gradient Boosting) перед простыми линейными методами и SVR.
4. С помощью метода GridSearchCV произведена оптимизация внутренней структуры алгоритмов, обеспечившая достижение высокого качества предсказания (целевой коэффициент детерминации $R^2 = 0.915$).
5. Инструментами Streamlit спроектировано и запущено интерактивное веб-приложение, реализующее сквозной интерфейс прогнозирования в реальном времени с возможностью изменения гиперпараметров пользователем.

Практическая значимость. Разработанный комплекс моделей и программный прототип веб-сервиса могут быть непосредственно интегрированы в аналитическую инфраструктуру страховых медицинских компаний для автоматизации андеррайтинга, оперативного гибкого скоринга клиентов и динамической оптимизации тарифных сеток.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Мюллер, А. Введение в машинное обучение с помощью Python. Руководство для специалистов по работе с данными / А. Мюллер, С. Гвидо. – М.: Альпина Паблишер, 2024. – 480 с.
2. Шарден, Б. Крупномасштабное машинное обучение на Python / Б. Шарден, Т. Массарон. – М.: ДМК Пресс, 2021. – 356 с.
3. Документация библиотеки Scikit-learn [Электронный ресурс]. – Режим доступа: <https://scikit-learn.org/stable/> (дата обращения: 20.05.2026).
4. Официальное руководство фреймворка Streamlit [Электронный ресурс]. – Режим доступа: <https://docs.streamlit.io/> (дата обращения: 20.05.2026).
5. Страница набора данных Medical Insurance Cost Dataset (Kaggle) [Электронный ресурс]. – Режим доступа: <https://www.kaggle.com/datasets/mirzayasirabdullah07/medical-insurance-cost-dataset> (дата обращения: 20.05.2026).